Universidad de Murcia

Máster Universitario en Bioinformática

Trabajo final Análisis de Datos Ómicos

Caracterización transcriptómica de la respuesta a doxorrubicina y bortezomib en cáncer de mama mediante RNA-Seq

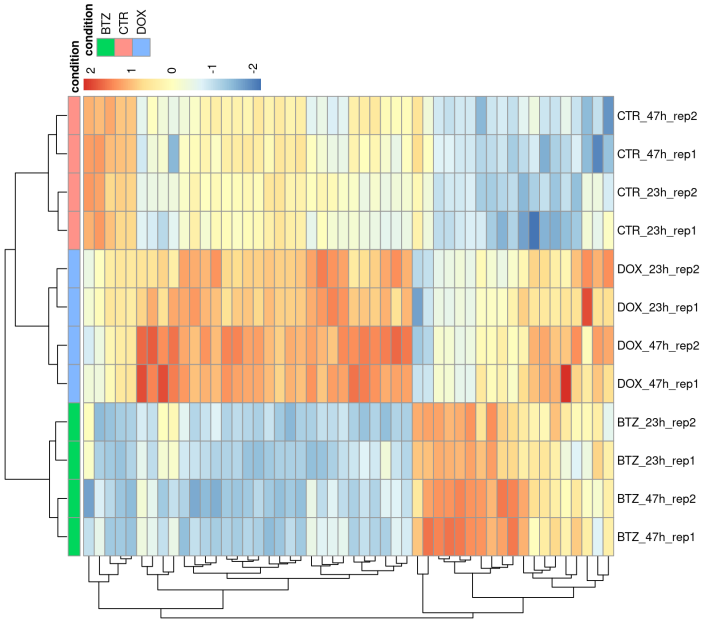

Irene Xue-Feng Lope Mateo
Carmen Pellicer Teruel
Rebeca Soto Campillo

Índice

1. Introducción **2**

2. Objetivos **2**

3. Metodología **3**

3.1. Obtención de los datos 3

3.2. Importación y organización de datos en Galaxy 3

3.3. Control de calidad de los datos de secuenciación 4

3.3.1. Análisis de calidad mediante FastQC 4

3.3.2. Integración de resultados mediante MultiQC 4

3.4. Alineamiento de lecturas al genoma de referencia 5

3.5. Cuantificación de la expresión génica 5

3.6. Análisis de expresión diferencial con DESeq2 6

3.7. Análisis de enriquecimiento funcional 6

4. Resultados y Discusión **7**

4.1. Control de calidad e integración de resultados 7

4.2. Preprocesamiento y alineamiento 8

4.3. Cuantificación de la expresión génica 8

4.4. Expresión diferencial 9

4.5. Análisis exploratorio (PCA y heatmap) 9

4.6. Enriquecimiento funcional 11

4.7. GSEA 12

5. Conclusiones **13**

1. Introducción

El cáncer es uno de los principales problemas de salud a nivel mundial[1], tanto por su alta incidencia como por su impacto en la mortalidad. Dentro de esta patología, el cáncer de mama es el más común en mujeres, lo que lo convierte en un área clave de investigación. Sin embargo, su heterogeneidad molecular sigue siendo un desafío importante para desarrollar tratamientos efectivos.

El cáncer de mama triple negativo (TNBC) es un subtipo especialmente agresivo, definido por la ausencia de los receptores hormonales y del receptor HER2 [2]. Esta característica limita las opciones terapéuticas y se asocia con mayor riesgo de recaída y metástasis, así como con una tendencia a desarrollar resistencia a la quimioterapia. Comprender los mecanismos que subyacen a esta resistencia es crucial para diseñar nuevas estrategias de tratamiento.

Fármacos como la doxorrubicina, ampliamente usados en TNBC, ven su eficacia limitada por esta resistencia [3]. En paralelo, el bortezomib, un inhibidor del proteasoma, ha surgido como una opción prometedora para contrarrestar mecanismos de resistencia asociados a la inflamación y la supervivencia celular [4].

Por otro lado, las tecnologías de secuenciación masiva, como el RNA-seq, han transformado la investigación en cáncer, permitiendo analizar de forma global la expresión génica, identificar biomarcadores y comprender mejor las rutas moleculares involucradas en la respuesta a los tratamientos. El análisis de expresión diferencial se ha consolidado como una herramienta clave para detectar estos cambios y orientar futuras estrategias terapéuticas.

Para facilitar la transparencia y la reproducibilidad del análisis, todos los materiales utilizados en este trabajo (scripts, archivos de configuración del pipeline y resultados intermedios) se encuentran disponibles públicamente en el repositorio de GitHub:

`https://github.com/rebesoca/BreastCancer-RNAseq`

De este modo, cualquier persona interesada puede consultar y reutilizar los métodos empleados.

El historial completo del análisis realizado en Galaxy se encuentra disponible en el siguiente enlace:

`https://usegalaxy.eu/u/ix.lopemateo/h/rna-seq-analysis`

2. Objetivos

El presente trabajo tiene como objetivo principal analizar los perfiles de expresión génica en modelos de cáncer de mama triple negativo sometidos a distintos tratamientos farmacológicos, con el fin de identificar genes y rutas moleculares implicadas en la respuesta terapéutica y en los mecanismos de resistencia. Esto permitirá comprender mejor cómo los distintos tratamientos afectan a la regulación génica y qué rutas moleculares podrían estar implicadas en la sensibilidad o resistencia a los fármacos. Para ello, se ha implementado un pipeline bioinformático basado en datos de RNA-seq, que permite una aproximación sistemática y reproducible en el estudio transcriptómico en oncología.

Para alcanzar este objetivo principal, se plantean objetivos específicos:

- **Identificar los cambios en la expresión génica inducidos por cada tratamiento.**
- **Comparar las respuestas entre fármacos con mecanismos distintos.**
- **Detectar posibles marcadores asociados a resistencia a los fármacos.**

3. Metodología

La metodología que vamos a seguir en este trabajo se enmarca dentro de un pipeline bioinformático estándar para el análisis de expresión diferencial a partir de datos de RNA-seq. El flujo de trabajo (Figura1) se estructuró en seis etapas secuenciales: obtención y organización de los datos de secuenciación, control de calidad (FastQC y MultiQC), preprocesamiento de las lecturas, alineamiento al genoma de referencia humano, cuantificación de la expresión génica y análisis de expresión diferencial. Todos los análisis fueron ejecutados en la plataforma Galaxy, que permite la integración de herramientas bioinformáticas en un entorno reproducible y accesible. El conjunto de datos empleado corresponde al experimento GSE287429, que incluye muestras de organoides de cáncer de mama triple negativo (TNBC) sometidas a tres condiciones experimentales (control (CTR), doxorrubicina (DOX) y bortezomib (BTZ)) en dos tiempos de exposición (23 h y 47 h) con dos réplicas biológicas por condición, sumando un total de 12 muestras analizadas.

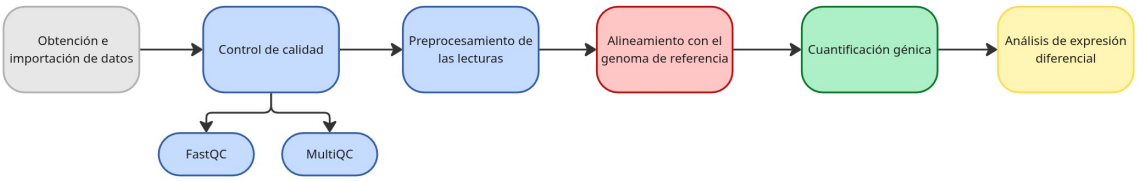

Figura 1: Esquema del pipeline bioinformático empleado en el análisis de expresión diferencial.

3.1. Obtención de los datos

Los datos de secuenciación empleados en este trabajo se obtuvieron a partir del repositorio público Gene Expression Omnibus (GEO) [5], bajo el código GSE287429 [6, 7]. Este conjunto de datos incluye experimentos de RNA-Seq en *Homo sapiens* correspondientes a tres condiciones experimentales: control (CTR), tratamiento con doxorrubicina (DOX) y tratamiento con bortezomib (BTZ), cada una de ellas evaluada en dos tiempos (23 h y 47 h) con dos réplicas biológicas por condición. Para su obtención, se utilizaron los identificadores de corrida (SRR) asociados a cada muestra.

3.2. Importación y organización de datos en Galaxy

Los datos generados en el apartado anterior fueron importados a la plataforma Galaxy [8], utilizada como entorno de trabajo para la ejecución de todos los análisis bioinformáticos realizados en este estudio.

Para ello, se empleó la opción *Paste/Fetch data*, que permite importar directamente los datos a partir de sus URLs. Tras importar los datos se estandarizó su nomenclatura, tratando de evitar errores en etapas posteriores. Para lograrlo se remplazaron los identificadores técnicos asociados a sus accesiones (SRR) por identificadores con interpretación biológica compuestos por las condiciones experimentales de las muestras.

3.3. Control de calidad de los datos de secuenciación

3.3.1. Análisis de calidad mediante FastQC

Con el objetivo de evaluar la calidad de los datos de secuenciación, se llevó a cabo un análisis de control de calidad utilizando la herramienta *FastQC*.

Dado que *FastQC* analiza archivos FASTQ de forma individual[1], cada muestra fue evaluada por separado para sus lecturas *forward* (R1) y *reverse* (R2). En consecuencia, se generaron un total de 24 análisis independientes (uno por cada archivo FASTQ), produciendo dos tipos de salida por archivo: un informe visual en formato HTML (*Webpage*)[2] y un archivo comprimido con los datos brutos del análisis (*RawData*)[3].

Los informes generados incluyen métricas clave para la evaluación de la calidad de las lecturas, que son parámetros clave para identificar problemas técnicos en los datos que puedan afectar a los análisis posteriores.

3.3.2. Integración de resultados mediante MultiQC

Debido al elevado número de informes generados por *FastQC*, se utilizó la herramienta *MultiQC* para integrar y resumir los resultados en un único informe global[4]. Así, se facilita la visualización e interpretación de las métricas de calidad de todas las muestras de forma conjunta.

El informe generado permite por tanto, identificar patrones globales, posibles desviaciones entre condiciones y problemas sistemáticos en los datos.

Preprocesamiento de lecturas con *fastp*.

Con el objetivo de eliminar secuencias adaptadoras residuales y mejorar la calidad de las lecturas en sus regiones terminales, se aplicó un paso de preprocesamiento utilizando la herramienta *fastp*. Este procedimiento se llevó a cabo sobre la colección de datos `all_samples_paired`, manteniendo la estructura de lecturas *paired-end* sin realizar su fusión. Empleando detección automática, con la opción de identificación de adaptadores para datos *paired-end*. Adicionalmente, se aplicó un filtrado de calidad moderado, estableciendo un umbral de calidad Phred de 20 y permitiendo hasta un 40 % de bases de baja calidad por lectura, con el fin de preservar la mayor cantidad de información posible.

Asimismo, se implementó un recorte específico en el extremo 3' de las lecturas (*cut by quality*

[1] Para visualizarlo, acceda a FastQC_results
[2] Para visualizarlo, acceda a FastQC_results: Webpage
[3] Para visualizarlo, acceda a FastQC_results: RawData
[4] Para visualizarlo, acceda a MultiQC

in tail), utilizando una ventana deslizante de tamaño 4 y un umbral de calidad media de 20. En este paso se logró eliminar de forma selectiva las bases de menor calidad observadas en las regiones terminales, así como posibles restos de adaptadores, sin introducir un recorte excesivo. Tras el procesamiento se estableció una longitud mínima de lectura de 50 pb, descartando el resto.

De esta manera, tras el preprocesamiento se obtuvieron lecturas depuradas siguiendo un enfoque conservador, que permitió optimizar el alineamiento posterior sin comprometer la longitud ni la cobertura de las secuencias.

3.4. Alineamiento de lecturas al genoma de referencia

Las lecturas obtenidas del apartado anterior fueron alineadas al genoma de referencia humano *Homo sapiens* GRCh38 (hg38) [9] utilizando la herramienta *RNA STAR* (*Spliced Transcripts Alignment to a Reference*), utilizando el índice preconstruido disponible en Galaxy.

El alineamiento se realizó sobre datos de secuenciación *paired-end*, manteniendo la estructura de pares tras el preprocesamiento. Dado que las librerías utilizadas corresponden a un protocolo *stranded* (TruSeq Stranded mRNA), se configuró el análisis en modo *reverse stranded*, permitiendo una correcta asignación de las lecturas a la hebra transcrita. No se incorporó un archivo de anotación génica externo (GTF) durante el alineamiento, permitiendo a STAR detectar de novo las uniones de splicing a partir de los datos.

Como salida, se generaron archivos en formato BAM [10] ordenados por coordenadas genómicas, facilitando su uso en etapas posteriores de análisis. Asimismo, se activó la opción de obtención de conteos por gen (*GeneCounts*), permitiendo una primera cuantificación de la expresión génica directamente a partir de los alineamientos.

3.5. Cuantificación de la expresión génica

Sobre los archivos de alineamiento en formato BAM generados, se realizó la cuantificación de la expresión génica usando la herramienta *featureCounts*[5] del paquete Subread.

Como archivo de anotación se empleó un fichero en formato GTF correspondiente al genoma humano GRCh38, que contiene la información estructural de los genes y sus exones. Este se obtuvo a partir del repositorio público de UCSC Genome Browser (hg38) [11], mediante descarga directa desde la siguiente URL: `https://hgdownload.soe.ucsc.edu/goldenPath/hg38/bigZips/genes/hg38.ncbiRefSeq.gtf.gz`. Este fichero contiene la anotación de genes basada en RefSeq y fue utilizado para la asignación de lecturas a características génicas durante el proceso de cuantificación con *featureCounts*.

La cuantificación se realizó a nivel de gen, considerando únicamente las regiones exónicas (*feature type = exon*) y agrupando las lecturas en función del identificador `gene_id`.

Dado que los datos corresponden a secuenciación *paired-end*, se activó la opción de conteo por fragmentos en lugar de lecturas individuales (*count fragments instead of reads*), asegurando que cada par de lecturas se contabilizara como una única unidad. Asimismo, se especificó el carácter

[5] Para visualizar los resultados, acceda a featureCounts_results

stranded de las librerías, configurando el análisis en modo *reverse stranded*, en concordancia con el protocolo de preparación de librerías empleado (TruSeq Stranded mRNA).

Se utilizaron como entrada los archivos BAM organizados en colecciones, lo que permitió realizar la cuantificación de forma simultánea para todas las muestras. El resto de parámetros se mantuvieron en sus valores por defecto, incluyendo los criterios de asignación de lecturas y manejo de lecturas multimapeadas o ambiguas.

Como resultado, se obtuvo una matriz de conteos que recoge el número de fragmentos asignados a cada gen en cada muestra, constituyendo la base para los análisis posteriores de expresión diferencial.

Sin embargo, dichos archivos presentaban una doble cabecera, incluyendo una segunda fila redundante con la etiqueta `Geneid`, lo que impedía su uso directo en análisis posteriores.

Para solventar este problema, se aplicó la herramienta *Remove beginning of a file* en Galaxy, eliminando la primera línea adicional de cada archivo. De este modo, se generaron tablas en formato tabular correctamente estructuradas, con una única cabecera y listas para su análisis.

3.6. Análisis de expresión diferencial con DESeq2

Inicialmente, se intentó realizar el análisis de expresión diferencial mediante la herramienta DESeq2 disponible en Galaxy. No obstante, debido a errores de ejecución en dicha implementación, se optó por realizar el análisis en un entorno local utilizando *R*.

Para ello, los archivos de conteo preprocesados se descargaron y se desarrolló un script específico denominado `script_deseq2.R`[6]. En este script se llevó a cabo el análisis completo de expresión diferencial utilizando el paquete `DESeq2`, incluyendo la normalización de los datos, la estimación de dispersión y la identificación de genes diferencialmente expresados.

El uso de *R* permitió, además, una mayor flexibilidad en el análisis de los resultados, facilitando la generación de visualizaciones (como PCA, volcano plots y heatmaps) y la exploración detallada de los genes diferencialmente expresados junto a un análisis de enriquecimiento funcional.

3.7. Análisis de enriquecimiento funcional

Se llevó a cabo un análisis de enriquecimiento funcional utilizando las bases de datos Gene Ontology (GO) y Kyoto Encyclopedia of Genes and Genomes (KEGG) para interpretar biológicamente los genes diferencialmente expresados. Este análisis permite identificar procesos biológicos y rutas celulares que se encuentran sobrerrepresentados en el conjunto de genes significativos, proporcionando una visión global de los mecanismos moleculares afectados por los tratamientos.

En primer lugar, los genes diferencialmente expresados se convirtieron a identificadores Entrez mediante el paquete `org.Hs.eg.db`, necesario para su uso en las herramientas de enriquecimiento. Posteriormente, se realizó el análisis de enriquecimiento de términos GO empleando la función `enrichGO` del paquete `clusterProfiler`, considerando la ontología *Biological Process* (BP). Se utilizó el método de corrección por comparaciones múltiples de Benjamini-Hochberg (`BH`) y se estableció un umbral de significancia de $p.adjust < 0{,}05$.

[6] Disponible en GitHub: Script_R

De forma complementaria, se llevó a cabo el análisis de enriquecimiento de rutas KEGG mediante la función `enrichKEGG`, especificando el organismo *Homo sapiens* (código "hsa") y aplicando igualmente un umbral de significancia de $p.adjust < 0{,}05$.

Los resultados de ambos análisis se visualizaron mediante gráficos de tipo *dotplot*, que permiten representar de forma simultánea la significancia estadística, el número de genes implicados y la proporción de genes enriquecidos en cada término o ruta.

Para complementar el análisis de enriquecimiento por sobreexpresión, se realizó un *Gene Set Enrichment Analysis* (GSEA) utilizando el paquete `clusterProfiler` en R. GSEA evalúa la distribución de conjuntos de genes predefinidos (términos GO y rutas KEGG) a lo largo de una lista de todos los genes ordenados por su log fold change, identificando aquellos conjuntos que se acumulan preferentemente en los extremos superior o inferior de la lista. Este método presenta la ventaja de no requerir un umbral de significancia arbitrario para la selección de genes diferencialmente expresados, permitiendo detectar cambios coordinados en rutas biológicas incluso cuando los cambios individuales de expresión son moderados.

4. Resultados y Discusión

4.1. Control de calidad e integración de resultados

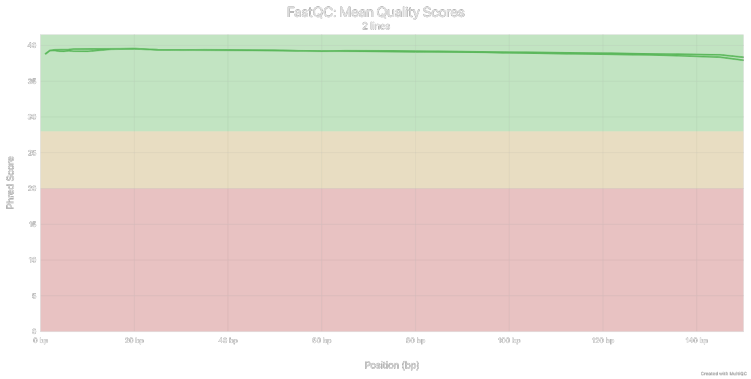

Figura 2: Distribución de la calidad por base de las lecturas (Phred score) obtenida mediante MultiQC.

El análisis conjunto mediante *MultiQC* mostró una alta consistencia entre muestras, evidenciada por la superposición de las curvas de calidad. Este comportamiento indica una elevada reproducibilidad y ausencia de valores atípicos, lo que respalda la fiabilidad del dataset. La calidad por base fue alta a lo largo de todas las lecturas, con valores Phred mayoritariamente superiores a Q30 (en torno a Q38–40). Aunque se observó una ligera disminución hacia los extremos finales, este patrón es habitual en datos de *Illumina* y no compromete el análisis.

El contenido de adaptadores fue bajo, concentrándose principalmente en los extremos de las lecturas y con valores máximos cercanos al 5 %. Asimismo, la distribución del contenido GC fue unimodal y consistente entre muestras, sin indicios de sesgos o contaminaciones. En cuanto a la duplicación de secuencias, se detectaron niveles moderados, atribuibles a la alta expresión de ciertos genes y no a artefactos técnicos. Estos resultados indican que los datos son fiables y pueden utilizarse con confianza en los análisis posteriores.

4.2. Preprocesamiento y alineamiento

El preprocesamiento con *fastp* tuvo un impacto mínimo, conservándose aproximadamente el 99 % de las lecturas, lo que confirma la alta calidad inicial de las secuencias.

El alineamiento con *RNA STAR* mostró un rendimiento elevado, con más del 90 % de lecturas mapeadas de forma única. Las lecturas multimapeadas se mantuvieron dentro de lo esperado en RNA-seq, mientras que las no alineadas fueron mínimas. Además, se detectó un elevado número de eventos de splicing, predominando las uniones canónicas.

```
                                Started job on |       Mar 25 13:05:59
                            Started mapping on |       Mar 25 13:06:14
                                   Finished on |       Mar 25 13:08:15
       Mapping speed, Million of reads per hour |       340.14

                          Number of input reads |       11432508
                      Average input read length |       299
                                    UNIQUE READS:
                   Uniquely mapped reads number |       10580068
                        Uniquely mapped reads % |       92.54%
                          Average mapped length |       297.66
                       Number of splices: Total |       8518198
            Number of splices: Annotated (sjdb) |       0
                       Number of splices: GT/AG |       8437854
                       Number of splices: GC/AG |       57396
                       Number of splices: AT/AC |       5404
               Number of splices: Non-canonical |       17544
                      Mismatch rate per base, % |       0.24%
                         Deletion rate per base |       0.01%
                        Deletion average length |       2.02
                        Insertion rate per base |       0.01%
                       Insertion average length |       1.75
                            MULTI-MAPPING READS:
        Number of reads mapped to multiple loci |       733292
             % of reads mapped to multiple loci |       6.41%
        Number of reads mapped to too many loci |       12749
             % of reads mapped to too many loci |       0.11%
                                  UNMAPPED READS:
  Number of reads unmapped: too many mismatches |       0
       % of reads unmapped: too many mismatches |       0.00%
            Number of reads unmapped: too short |       101052
                 % of reads unmapped: too short |       0.88%
                Number of reads unmapped: other |       5347
                     % of reads unmapped: other |       0.05%
```

Figura 3: Estadísticas de alineamiento generadas por *RNA STAR* para la muestra `CTR_47h_rep1`, incluyendo métricas de mapeo, eventos de splicing y calidad del alineamiento.

Las bajas tasas de error (desajustes, inserciones y deleciones) indican una alta fidelidad en el alineamiento, validando la calidad del pipeline.

4.3. Cuantificación de la expresión génica

La cuantificación mediante *featureCounts* mostró una asignación mayoritaria de lecturas a genes, con un bajo porcentaje de lecturas ambiguas. Las lecturas no asignadas correspondieron principalmente a regiones no anotadas o multimapeadas, lo cual es esperable.

Como resultado, se obtuvo una matriz de conteos que representa la expresión génica en todas las muestras, utilizada posteriormente para el análisis de expresión diferencial.

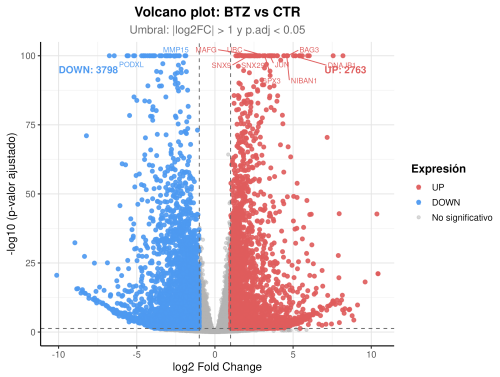

(a) Volcano plot de la comparación de BTZ frente a CTR. Se representan los genes diferencialmente expresados. Los genes sobreexpresados (UP) se muestran en rojo y los reprimidos (DOWN) en azul.

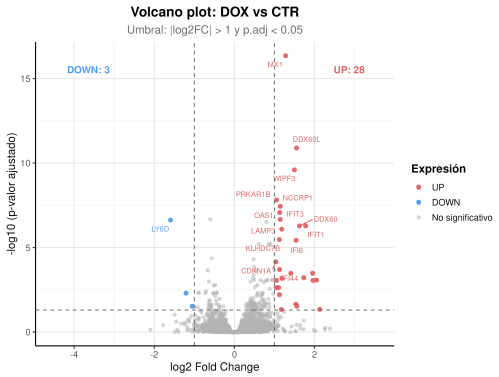

(b) Volcano plot de la comparación de DOX frente a CTR. Se representan los genes diferencialmente expresados. Los genes sobreexpresados (UP) se muestran en rojo y los reprimidos (DOWN) en azul.

Figura 4

4.4. Expresión diferencial

DOX vs CTR El tratamiento con doxorrubicina (DOX) produjo una respuesta moderada, con 155 genes diferencialmente expresados ($padj < 0{,}05$), de los cuales 31 mostraron cambios relevantes ($|log2FC| > 1$). La mayoría de los genes no presentaron cambios significativos, lo que indica un efecto específico. Entre los genes regulados destacan MX1, OAS1 e IFIT3, asociados a la respuesta interferón, lo que sugiere activación de mecanismos de estrés celular e inmunidad innata. El volcano plot (Figura 4B) refleja una distribución compacta, coherente con un efecto localizado.

BTZ vs CTR El tratamiento con bortezomib (BTZ) indujo una respuesta transcriptómica global, con aproximadamente 11.700 genes diferencialmente expresados. Más de 6500 genes presentaron cambios elevados, indicando una fuerte reprogramación celular. Los genes destacados (DNAJB1, ZFAND2A, JUN, UBC) están relacionados con estrés proteico y el sistema ubiquitina-proteasoma, en línea con el mecanismo de acción del fármaco. El volcano plot (Figura 4A) muestra una amplia dispersión, reflejando la magnitud del efecto.

BTZ vs DOX La comparación entre BTZ y DOX mostró resultados similares a BTZ vs CTR, indicando que el efecto de BTZ domina claramente. Los genes implicados refuerzan la activación de respuestas al estrés proteico y procesos celulares asociados.

4.5. Análisis exploratorio (PCA y heatmap)

El PCA (Figura 5) mostró que el primer componente explica el 96 % de la varianza, separando claramente las muestras BTZ del resto. En cambio, DOX y CTR se agrupan de forma cercana, indicando perfiles similares.

El heatmap (Figura 6) confirmó estos resultados, mostrando un clustering claro por condición

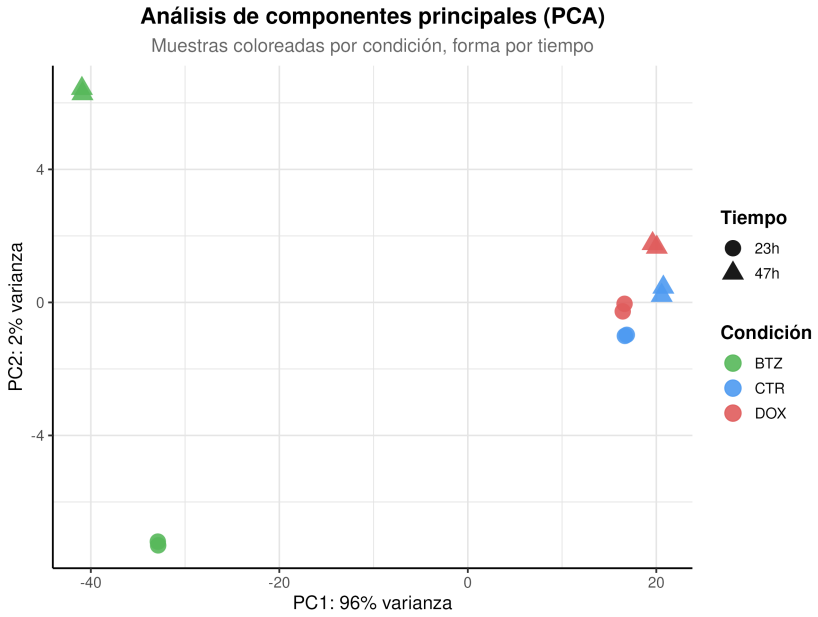

Figura 5: Análisis de componentes principales (PCA) para las 12 muestras analizadas. Cada punto representa una muestra, coloreada según la condición experimental y con forma según el tiempo de exposición.

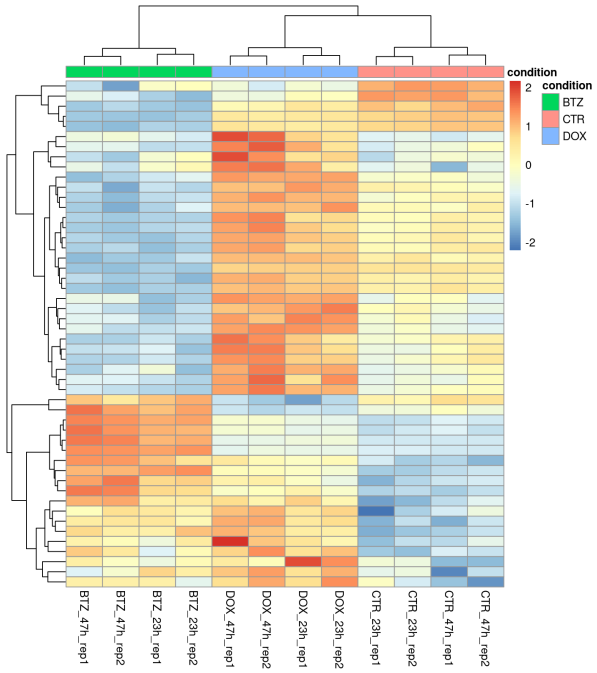

Figura 6: Mapa de calor de los genes diferencialmente expresados entre las tres condiciones experimentales. Las muestras se agrupan jerárquicamente por columnas y los genes por filas. La escala de color representa la expresión génica normalizada. Las barras superiores indican la condición experimental de cada muestra.

experimental. Las muestras BTZ forman un grupo diferenciado, mientras que DOX se aproxima al control. Además, los replicados presentan alta consistencia y no se observan diferencias marcadas entre tiempos de tratamiento.

4.6. Enriquecimiento funcional

Con el objetivo de interpretar biológicamente los genes diferencialmente expresados, se realizó un análisis de enriquecimiento funcional utilizando las bases de datos Gene Ontology (GO) y KEGG. Este análisis permite identificar procesos biológicos y rutas celulares sobrerrepresentadas en el conjunto de genes significativos, proporcionando una visión global de los mecanismos moleculares afectados por los tratamientos.

En el análisis de GO (categoría *Biological Process*) (Figura 7), se observó un claro predominio de términos relacionados con la respuesta antiviral y la inmunidad innata. Entre los procesos más significativamente enriquecidos destacan *response to virus*, *defense response to virus*, *viral process*, *viral life cycle* y *regulation of viral genome replication*. Asimismo, se identificaron términos asociados a la señalización de interferón, como *response to type I interferon* y *antiviral innate immune response*.

La coherencia entre estos términos sugiere la activación de un programa transcriptómico coordinado característico de la respuesta inmune frente a infecciones virales. Es importante destacar que este tipo de enriquecimiento no implica necesariamente la presencia de una infección viral real, sino que refleja la activación de rutas celulares que comparten componentes moleculares con la respuesta antiviral, como ocurre en situaciones de estrés celular o daño proteico.

En cuanto a la magnitud del enriquecimiento, los valores de significación ajustada (*p.adjust*) fueron extremadamente bajos (del orden de 10^{-4}–10^{-5}), junto con valores elevados de *GeneRatio*, lo que indica que una proporción considerable de los genes diferencialmente expresados participa en estos procesos, reforzando la robustez del resultado.

El análisis de enriquecimiento basado en KEGG (Figura 7) mostró resultados altamente consistentes con los obtenidos en GO. Se identificaron múltiples rutas asociadas a infecciones virales, como *Epstein-Barr virus infection*, *Influenza A*, *Hepatitis C*, *Coronavirus disease (COVID-19)* y *Measles*. Aunque a primera vista estos resultados podrían sugerir la implicación directa de infecciones, en realidad reflejan la activación de conjuntos de genes compartidos entre distintas rutas virales, principalmente relacionados con la respuesta interferón y la inmunidad innata.

Además, se observaron rutas relacionadas con procesos inmunitarios e inflamatorios, como *Systemic lupus erythematosus*, *Rheumatoid arthritis*, *Antigen processing and presentation* y *Graft-versus-host disease*, lo que respalda la activación de mecanismos de respuesta inmune más amplios. También se identificaron rutas vinculadas a procesos celulares como *Phagosome* y *Viral carcinogenesis*, que reflejan la implicación de mecanismos de procesamiento intracelular y respuesta al estrés.

En conjunto, los resultados de GO y KEGG convergen en una misma interpretación biológica: los tratamientos inducen una activación robusta de programas de respuesta inmune innata, particularmente aquellos asociados a la señalización de interferón y a la defensa antiviral. Esta activación es coherente con el resto de análisis realizados, incluyendo la separación observada en el PCA, la elevada cantidad de genes diferencialmente expresados en determinadas condiciones y los patrones de co-expresión identificados en el heatmap.

Estos hallazgos sugieren que el tratamiento, especialmente en el caso de bortezomib (BTZ), desencadena una reprogramación transcriptómica amplia que involucra mecanismos de estrés celular y activación inmunitaria, lo que podría estar relacionado con su mecanismo de acción a nivel molecular.

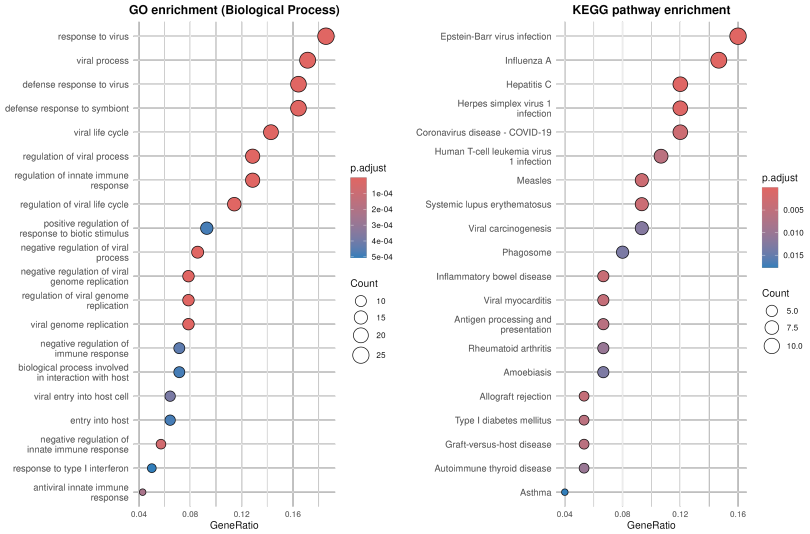

Figura 7: Enriquecimiento funcional con GO (izquierda) y KEGG (derecha).

4.7. GSEA

El análisis GSEA (Figura 8) confirmó diferencias claras entre tratamientos. En BTZ vs DOX y BTZ vs CTR destacan procesos relacionados con proteasoma, plegamiento proteico y respuesta a proteínas mal plegadas, junto con autofagia.

Por el contrario, DOX vs CTR mostró enriquecimiento en procesos antivirales e interferón tipo I. En conjunto, estos resultados diferencian claramente los mecanismos de acción: BTZ afecta la homeostasis proteica, mientras que DOX induce respuestas asociadas a daño celular.

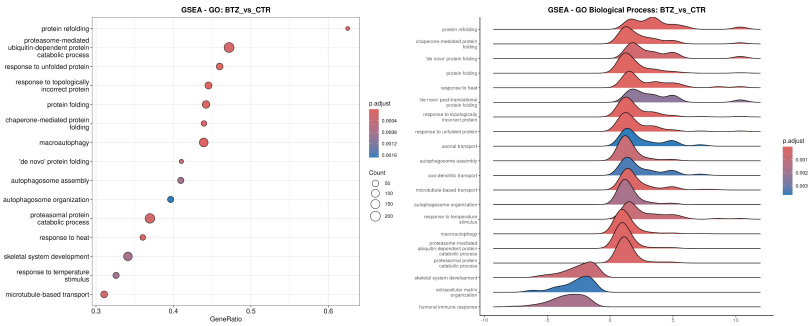

Figura 8: GSEA en la comparación BTZ vs CTR, con GO (izquierda) y GO BP (derecha).

5. Conclusiones

A lo largo de este trabajo se ha abordado el análisis transcriptómico de la respuesta a doxorrubicina y bortezomib en modelos de cáncer de mama triple negativo mediante datos de RNA-seq, siguiendo un pipeline bioinformático completo y reproducible. Más allá de los resultados concretos, uno de los aspectos más relevantes es que el flujo de trabajo aplicado ha demostrado ser sólido, coherente y adecuado para este tipo de estudios, lo que refuerza la confianza en las conclusiones obtenidas.

En primer lugar, conviene destacar que la calidad de los datos ha sido consistentemente alta en todas las etapas del análisis. Desde el control inicial hasta la cuantificación, no se han detectado problemas técnicos significativos que pudieran sesgar la interpretación. Esto permite asumir, con bastante seguridad, que las diferencias observadas responden realmente a efectos biológicos derivados de los tratamientos y no a artefactos experimentales.

Uno de los hallazgos más claros del estudio es que ambos fármacos inducen respuestas transcriptómicas muy distintas. La doxorrubicina, aunque produce cambios detectables, lo hace de forma más contenida y específica, afectando a un subconjunto relativamente reducido de genes. En cambio, el bortezomib desencadena una alteración mucho más profunda, con una reprogramación global de la expresión génica que afecta a miles de genes. Esta diferencia no solo aparece en el análisis de expresión diferencial, sino que se refleja de forma consistente en el PCA y en el heatmap, donde las muestras tratadas con BTZ se separan de manera muy marcada del resto.

Desde el punto de vista funcional, los resultados también encajan bien con lo esperado. La activación de rutas relacionadas con respuesta antiviral e interferón sugiere que las células están activando programas de defensa frente a estrés intracelular. Es interesante señalar que este tipo de señal no implica necesariamente una infección real, sino que suele aparecer como respuesta general al daño o a la alteración del equilibrio celular. En este sentido, los resultados no solo son coherentes internamente, sino también con lo descrito en la literatura.

Si se comparan ambos tratamientos de forma más directa, se observa que las diferencias van más allá de la magnitud del efecto. DOX parece actuar de manera más dirigida, probablemente asociada al daño en el ADN, mientras que BTZ afecta a procesos más globales relacionados con la homeostasis proteica, el proteasoma y el estrés proteotóxico. Esta distinción aporta una visión bastante clara de que no solo estamos ante dos fármacos con distinta intensidad de respuesta, sino con mecanismos de acción bien diferenciados.

No obstante, el trabajo no está exento de limitaciones. El número de réplicas es reducido, lo que puede influir en la potencia estadística del análisis, y el uso de datos públicos implica que no se tiene control sobre todas las variables experimentales. Además, los resultados se apoyan exclusivamente en análisis bioinformáticos, por lo que sería necesario validarlos experimentalmente para confirmar su relevancia biológica real.

De cara a futuro, sería especialmente interesante profundizar en la validación de genes clave y explorar posibles estrategias combinadas entre ambos fármacos. Precisamente, el hecho de que DOX y BTZ actúen sobre mecanismos distintos abre la puerta a enfoques terapéuticos complementarios que podrían mejorar la eficacia en este tipo de tumores.

En conjunto, este trabajo no solo describe diferencias en la respuesta transcriptómica, sino que aporta una interpretación integrada de los mecanismos moleculares implicados, contribuyendo a en-

tender mejor cómo responden las células de cáncer de mama triple negativo a distintos tratamientos y qué vías podrían explotarse en el desarrollo de nuevas estrategias terapéuticas.

Referencias

[1] Hyuna Sung et al. "Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries". En: *CA: A Cancer Journal for Clinicians* 71.3 (2021), págs. 209-249. DOI: 10.3322/caac.21660.

[2] Rebecca Dent et al. "Triple-negative breast cancer: clinical features and patterns of recurrence". En: *Clinical Cancer Research* 13.15 Pt 1 (2007), págs. 4429-4434. DOI: 10.1158/1078-0432.CCR-06-3045.

[3] John L. Nitiss. "Targeting DNA topoisomerase II in cancer chemotherapy". En: *Nature Reviews Cancer* 9.5 (2009), págs. 338-350.

[4] J. B. Sunwoo et al. "Novel proteasome inhibitor PS-341 inhibits activation of nuclear factor-κB, cell survival, tumor growth, and angiogenesis in squamous cell carcinoma". En: *Clinical Cancer Research* 7.5 (2001), págs. 1419-1428.

[5] Ron Edgar, Michael Domrachev y Alex E. Lash. "Gene Expression Omnibus: NCBI gene expression and hybridization array data repository". En: *Nucleic Acids Research* 30.1 (2002), págs. 207-210. DOI: 10.1093/nar/30.1.207.

[6] Gene Expression Omnibus. *GSE287429*. https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE287429. Accedido: 2026-03-31. 2026.

[7] Ariestya Indah Permata Sari et al. "Drug repurposing identifies proteasome inhibitors as antiproliferative agents counteracting inflammation-driven chemoresistance in triple-negative breast cancer organoids". En: *Biomedicine & Pharmacotherapy* 190 (2025), pág. 118359. DOI: 10.1016/j.biopha.2025.118359.

[8] Enis Afgan et al. "The Galaxy platform for accessible, reproducible and collaborative biomedical analyses: 2018 update". En: *Nucleic Acids Research* 46.W1 (2018), W537-W544. DOI: 10.1093/nar/gky379.

[9] Valerie A. Schneider et al. "Evaluation of GRCh38 and de novo haploid genome assemblies demonstrates the enduring quality of the reference assembly". En: *Genome Research* 27.5 (2017), págs. 849-864. DOI: 10.1101/gr.213611.116.

[10] Heng Li et al. "The Sequence Alignment/Map format and SAMtools". En: *Bioinformatics* 25.16 (2009), págs. 2078-2079. DOI: 10.1093/bioinformatics/btp352.

[11] W. James Kent et al. "The Human Genome Browser at UCSC". En: *Genome Research* 12.6 (2002), págs. 996-1006. DOI: 10.1101/gr.229102.